

# ANÁLISE COMPARATIVA ENTRE ALGORITMOS DE PREDIÇÃO DE PREÇO PARA O BITCOIN

Trabalho de conclusão de curso

Mickael Osvaldo de Oliveira  
mickaelosvaldo1999@gmail.com

Bacharelado em Engenharia de Computação  
**Orientador:** Prof. Dr. Ciniro Aparecido Leite Nametala  
2025

## Sumário

- 1 Introdução
  - Contextualização
  - Objetivos
  - Justificativa
- 2 Fundamentação Teórica
  - Fundamentos conceituais
  - Modelos
  - Revisão Bibliográfica
- 3 Metodologia
  - Classificação da pesquisa
  - Solução proposta
- 4 Resultados
- 5 Conclusões
- 6 Referências

# Introdução

## Introdução – Contextualização

- A predição de preços em ativos financeiros teve sua origem atribuída a Bachelier (1900), na teoria conhecida como *Random Walks* (FAMA, 1965, 1995; COURTAULT *et al.*, 2000);
- Desde então, diversos métodos foram empregados com esse fim, destacando-se a análise técnica, fundamentalista e a utilização de modelos estatísticos como o ARIMA (ARIYO; ADEWUMI; AYO, 2014) ou aprendizado de máquina (FERDIANSYAH *et al.*, 2019);
- Com advento da *Blockchain* e *Bitcoin* por (NAKAMOTO, 2008), um novo mercado de ativos descentralizados surgiu, trazendo consigo a necessidade de novas abordagens de predição de preços (ZHANG; CAI; WEN, 2024).

## Introdução – Objetivos

### ■ Objetivo Geral

Analisar por meio comparativo o desempenho de algoritmos de predição de preço no contexto do *Bitcoin*.

### ■ Objetivos Específicos

- 1 Desenvolver a estrutura computacional necessária para selecionar, implementar e realizar previsões por meio de ferramentas tecnológicas adequadas;
- 2 Validar de algoritmos de redes neurais e compará-los, frente aos Benchmarks de interesse, a fim de determinar qual tem melhor desempenho;
- 3 Explorar de possíveis variações em métodos conhecidos, visando adaptá-los a um novo cenário;
- 4 Analisar se esses métodos de predição são rentáveis em uma base de dados real.

## Introdução – Justificativa

- Os criptoativos tem se tornado uma alternativa ao mercado financeiro tradicional, principalmente devido a sua volatilidade, tem sido adotado como ativo de alto risco (SOUSA *et al.*, 2022);
- Esta pesquisa busca comparar algoritmos de predição de preços, sejam estatísticos ou de aprendizado de máquina, a fim de avaliar seu desempenho em uma base de dados real;
- As tecnologias convergem para um cenário onde a análise de dados é cada vez mais importante, a inteligência artificial e a rede distribuída são a parte central da Web3;
- Os modelos utilizados serão o ARIMA, LSTM, BiLSTM e GRU. Em que todas as implementações estarão públicas no *GitHub*.

# Fundamentação Teórica


## Fundamentação Teórica – Fundamentos conceituais

- A ideia de Ativos Digitais descentralizados baseados em criptografia, ou criptomoedas, foi marcada por inúmeras tentativas anteriores, mas só foi implementada como advento da *Blockchain* por Nakamoto (2008) (MOLLING *et al.*, 2020);
- O ARIMA (*Autoregressive Integrated Moving Average*) tem suas raízes na econometria e na estatística. Sua história remonta ao trabalho pioneiro de Box e Jenkins (1970);
- A teoria de Redes Neurais Artificiais teve início com os estudos de Rosenblatt (1957), evoluiu com Rumelhart, Hinton e Williams (1986). Atualmente, é associada ao aprendizado profundo proposto por Goodfellow, Bengio e Courville (2016).



## Fundamentação Teórica – Bitcoin

- O Bitcoin é definido como um dinheiro eletrônico negociado diretamente entre pares, sem passar por uma instituição financeira (NAKAMOTO, 2008);
- Yuan e Wang (2018) descrevem a *Blockchain* como um registro compartilhado distribuído, onde a confiança mútua entre as partes é estabelecida por algoritmos matemáticos.



**Figura 1 - Transações na *Blockchain*.**

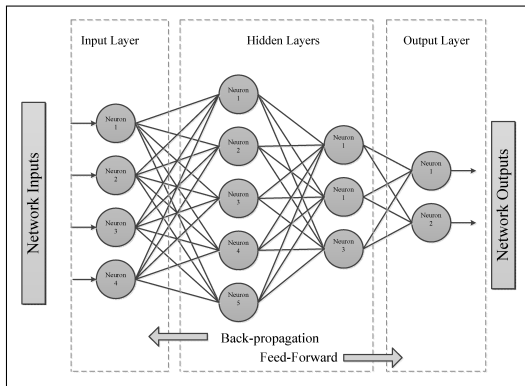
Figura que contém a árvore de Markle inserida na *Blockchain*.

Fonte: (NAKAMOTO, 2008).

## Fundamentação Teórica – ARIMA

- Abordagem sistemática para identificar, estimar e diagnosticar modelos de séries temporais, conhecida como metodologia Box-Jenkins (SHUMWAY; STOFFER, 2017);
- Atribui-se a cada uma das componentes do modelos as siglas  $p$ ,  $d$  e  $q$  representando o ajuste na série. O parâmetro  $p$  é a ordem do modelo AR,  $d$  é o grau de diferenciação (I) e  $q$  é a ordem do modelo MA.

# Fundamentação Teórica – Redes neurais artificiais




**Figura 2 - Multilayer Perceptron (MLP)**

Figura contendo uma MLP com duas camadas escondidas.

Fonte: (ABDOLRASOL *et al.*, 2021).

## Fundamentação Teórica – *Long Short-Term Memory (LSTM)*



**Figura 3 - Estrutura de uma LSTM**


Figura que contém a estrutura básica da LSTM.

Fonte: (GRAVES, 2012).

## Fundamentação Teórica – *Bidirecional LSTM (BiLSTM)*

- Processa a sequência em duas direções, do futuro para o passado e do passado para o futuro;
- Melhora o desempenho em tarefas que exigem a interpretação completa da sequência do *input*;
- Ao final, as saídas são concatenadas e passadas para a camada seguinte.

## Fundamentação Teórica – *Gated Recurrent Unit (GRU)*



**Figura 4 - Estrutura de uma GRU**

Figura que contém o diagrama de uma unidade de GRU.

Fonte: (CHEN *et al.*, 2021).

## Fundamentação Teórica – Revisão Bibliográfica

Pesquisadores	Ativo	Entradas	Saídas	Modelos	Métricas
(CAUX; BERNARDINI; VITERBO, 2020)	Bitcoin	Preço	Preço médio	LSTM, GRU	SMAPE
(FERDIANSYAH <i>et al.</i> , 2019)	Bitcoin	Preço	Preço	LSTM	RMSE
(SIAMI NAMINI; TAVAKOLI, 2019)	Ações	Preço	Preço	ARIMA, LSTM, BiLSTM	RMSE
(TRIPATHI; SHARMA, 2023)	Bitcoin	Preço ou indicadores	Preço	DANN, LSTM, BiLSTM, CNN-BiLSTM	RMSE, MAE, MAPE
Autor	Bitcoin	Preço, trocas e volume	Preço	ARIMA, LSTM, BiLSTM e GRU	MSE, MAPE, RMSE, $R^2$

### ■ Tabela 1 - Estudos similares

Tabela que enumera os principais estudos relacionados ao tema.

Fonte: Próprio autor.

# Metodologia



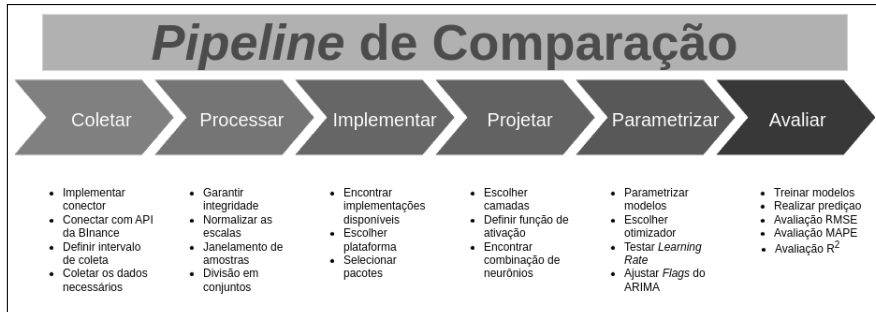
## Metodologia – Classificação da pesquisa

- Pode-se dizer, segundo a abordagem de Gerhardt e Silveira (2009), que a pesquisa adota uma abordagem quantitativa e experimental;
- A natureza aplicada do estudo busca não apenas compreender as nuances de cada algoritmo, mas também oferecer insights para a seleção e implementação dos mais eficazes;
- A metodologia descritiva permite uma análise detalhada dos resultados obtidos, destacando as diferenças significativas entre os modelos avaliados.

## Metodologia – Solução proposta

- Utilizou-se a linguagem de programação *Python* e bibliotecas para extrair, tratar e analisar os dados os presentes na *Binance*;
- O *Dataset* obtido conta com 26.304 amostras com o histórico de preços do Bitcoin em intervalos de 15 minutos, com dados como trocas, volume e preço entre Janeiro e Outubro de 2020;
- Para treinar as redes neurais foi utilizado um janelamento de 24 amostras (6 horas) enquanto o ARIMA foi parametrizado com o auto ARIMA.

## Metodologia – Solução proposta



**Figura 5 - Fluxo de comparação dos algoritmos**


Figura ilustrativa dos passos para a comparação dos algoritmos.

Fonte: Próprio autor.

# Resultados

## Resultados - LSTM

- O gráfico obtido após a aplicação do LSTM foi:




### Gráfico de saída do LSTM

Gráfico que retrata a comparação do previsto no LSTM (Azul) com o real (Laranja).

Fonte: Próprio autor.

## Resultados - BiLSTM

- O gráfico obtido após a aplicação do BiLSTM foi:




### ■ Gráfico 1 - Saída do BiLSTM

Gráfico que retrata a comparação do previsto no BiLSTM (Azul) com o real (Laranja).

Fonte: Próprio autor.

## Resultados - GRU

- O gráfico obtido após a aplicação do GRU foi:




### ■ Gráfico 2 - Saída do GRU

Gráfico que retrata a comparação do previsto no GRU (Azul) com o real (Laranja).

Fonte: Próprio autor.

## Resultados - ARIMA

- O gráfico obtido após a aplicação do ARIMA foi:



### Gráfico 3 - Saída do ARIMA

Gráfico que retrata a comparação do previsto no ARIMA (Azul) com o real (Laranja).

Fonte: Próprio autor.



## Resultados - Classificação dos modelos

- Os resultados finais após os testes dos modelos foram:

Posição	Nome	RMSE	$R^2$	MAPE
1°	ARIMA	28,9699	0,9989	0,0016
2°	GRU	86,1828	0,9799	0,0064
3°	LSTM	193.5493	0,8990	0,0145
4°	BiLSTM	207,2416	0,8842	0,0153

### ■ Tabela 2 - Resultados obtidos

Tabela contendo os erros e classificação de cada modelo no *Dataset* utilizado.

Fonte: Próprio autor.

## Conclusões

## Conclusões

- Foram exploradas diferentes métodos para a previsão do preço do Bitcoin em intervalos de 15 minutos, comparando métodos estatísticos e redes neurais;
- O modelo ARIMA obteve os melhores resultados no contexto, superando ligeiramente os modelos de rede neural ao apresentar previsões mais consistentes;
- Como continuidade para este trabalho, sugere-se a investigação de abordagens híbridas. Além disso, é possível expandir os testes para outros períodos e ativos financeiros.

## Referências I

ABDOLRASOL, M. G. M. *et al.* Artificial Neural Networks Based Optimization Techniques: A Review. **Electronics**, v. 10, n. 21, 2021. ISSN 2079-9292. DOI: 10.3390/electronics10212689. Disponível em: <https://www.mdpi.com/2079-9292/10/21/2689>.

ARIYO, A. A.; ADEWUMI, A. O.; AYO, C. K. Stock Price Prediction Using the ARIMA Model. In: 2014 UKSim-AMSS 16th International Conference on Computer Modelling and Simulation. 2014. p. 106–112. DOI: 10.1109/UKSim.2014.67.

BACHELIER, L. Théorie de la Spéculation. **Annales Scientifiques de L'Ecole Normale Supérieure**, v. 17, p. 21–88, 1900.

BOX, G. E. P.; JENKINS, G. M. ( M. **Time series analysis; forecasting and control**. Holden-Day, 1970.

## Referências II

CHEN, J. *et al.* Low-Cost and Device-Free Human Activity Recognition Based on Hierarchical Learning Model. **Sensors**, v. 21, p. 2359, 03/2021. DOI: 10.3390/s21072359.

COURTAULT, J.-M. *et al.* Louis Bachelier on the Centenary of "Théorie de la Spéculation". **Mathematical Finance**, v. 10, p. 339–353, 07/2000. DOI: 10.1111/1467-9965.00098.

FAMA, E. Random Walks in Stock Market Prices. **Financial Analysts Journal**, Routledge, v. 51, n. 1, p. 75–80, 1995.

FAMA, E. The Behavior of Stock-Market Prices. **The Journal of Business**, v. 38, p. 34, 1965.

## Referências III

FERDIANSYAH, F. *et al.* A LSTM-Method for Bitcoin Price Prediction: A Case Study Yahoo Finance Stock Market. **2019 International Conference on Electrical Engineering and Computer Science (ICECOS)**, p. 206–210, 10/2019. DOI: 10.1109/ICECOS47637.2019.8984499.

GERHARDT, T.; SILVEIRA, D. **Métodos de pesquisa**. 1. ed.: UFRGS, 01/2009. p. 120. ISBN 9788538600718.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016.

GRAVES, A. **Supervised Sequence Labelling with Recurrent Neural Networks**. Springer, 2012. v. 385, p. 1–131. (Studies in Computational Intelligence). ISBN 978-3-642-24796-5. Disponível em: <http://dx.doi.org/10.1007/978-3-642-24797-2>.

## Referências IV

MOLLING, G. *et al.* Cryptocurrency: A Mine of Controversies. **Journal of Information Systems and Technology Management**, v. 17, 12/2020. DOI: 10.4301/s1807-1775202017010.

NAKAMOTO, S. **Bitcoin**: A Peer-to-Peer Electronic Cash System. 2008. Disponível em: <https://bitcoin.org/bitcoin.pdf>. Acesso em: 15/03/2024.

ROSENBLATT, F. **The perceptron, a perceiving and recognizing automaton**. Ithaca, New York, 1957.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986. Disponível em: <https://doi.org/10.1038/323533a0>.

## Referências V

SHUMWAY, R. H.; STOFFER, D. S. ARIMA Models. In: TIME Series Analysis and Its Applications: With R Examples. Cham: Springer International Publishing, 2017. p. 75–163. ISBN 978-3-319-52452-8. DOI: 10.1007/978-3-319-52452-8\_3.

SOUSA, A. *et al.* Cryptocurrency adoption: a systematic literature review and bibliometric analysis. **EuroMed Journal of Business**, v. 17, p. 374–390, 05/2022. DOI: 10.1108/EMJB-01-2022-0003.

YUAN, Y.; WANG, F.-Y. Blockchain and Cryptocurrencies: Model, Techniques, and Applications. **IEEE Transactions on Systems, Man, and Cybernetics: Systems**, v. 48, n. 9, p. 1421–1428, 2018. DOI: 10.1109/TSMC.2018.2854904.

ZHANG, J.; CAI, K.; WEN, J. A survey of deep learning applications in cryptocurrency. **iScience**, v. 27, n. 1, p. 108509, 2024. ISSN 2589-0042. DOI: <https://doi.org/10.1016/j.isci.2023.108509>.



# Obrigado

Favor enviar as sugestões e os pedidos de correção para:  
[mickaelosvaldo1999@gmail.com](mailto:mickaelosvaldo1999@gmail.com)  
[ciniro.nametala@ifmg.edu.br](mailto:ciniro.nametala@ifmg.edu.br).

