

ANÁLISE COMPARATIVA ENTRE ALGORITMOS DE PREDIÇÃO DE PREÇO PARA O BITCOIN

Seminário de Qualificação de TCC

Mickael Osvaldo de Oliveira
mickaelosvaldo1999@gmail.com

Bacharelado em Engenharia de Computação
Orientador: Prof. Dr. Ciniro Aparecido Leite Nametala
2024

Sumário

- 1 Introdução
 - Contextualização
 - Objetivos
 - Justificativa
- 2 Fundamentação Teórica
 - Revisão Bibliográfica
 - Fundamentos conceituais
- 3 Metodologia
 - Classificação da pesquisa
 - Solução proposta
- 4 Resultados
- 5 Conclusões
- 6 Referências

Introdução

Contextualização do tema, objetivos e justificativa da pesquisa.

Introdução – Contextualização

- A predição de preços em ativos financeiros teve sua origem atribuída a Bachelier (1900), na teoria conhecida como *Random Walks* (FAMA, 1965, 1995);
- Desde então, diversos métodos foram empregados com esse fim, destacando-se a análise técnica, fundamentalista e a utilização de modelos estatísticos como o ARIMA (ARIYO; ADEWUMI; AYO, 2014) ou aprendizado de máquina (FERDIANSYAH *et al.*, 2019);
- Com advento da *Blockchain* e *Bitcoin* por (NAKAMOTO, 2008), um novo mercado de ativos descentralizados surgiu, trazendo consigo a necessidade de novas abordagens de predição de preços (ZHANG; CAI; WEN, 2024).

Introdução – Objetivos

■ Objetivo Geral

Analisar por meio comparativo o desempenho de algoritmos de predição de preço no contexto do *Bitcoin*.

■ Objetivos Específicos

- 1 Desenvolver a estrutura computacional necessária para selecionar, implementar e realizar previsões por meio de ferramentas tecnológicas adequadas;
- 2 Validar de algoritmos de redes neurais e compará-los, frente aos Benchmarks de interesse, a fim de determinar qual tem melhor desempenho;
- 3 Explorar de possíveis variações em métodos conhecidos, visando adaptá-los a um novo cenário;
- 4 Analisar se esses métodos de predição são rentáveis em uma base de dados real.

Introdução – Justificativa

- 1 Os criptoativos tem se tornado uma alternativa ao mercado financeiro tradicional, principalmente devido a sua volatilidade, tem sido adotado como ativo de alto risco (SOUSA *et al.*, 2022);
- 2 Esta pesquisa busca comparar algoritmos de predição de preços, sejam estatísticos ou de aprendizado de máquina, a fim de avaliar seu desempenho em uma base de dados real;
- 3 As tecnologias convergem para um cenário onde a análise de dados é cada vez mais importante, a inteligência artificial e a rede distribuída são a parte central da Web3;
- 4 Os modelos utilizados serão o ARIMA, LSTM, BiLSTM e GRU. Em que todas as implementações estarão públicas no GitHub.

Fundamentação Teórica

Revisão bibliográfica e fundamentos conceituais necessários para o desenvolvimento do tema.

Fundamentação Teórica – Revisão Bibliográfica

Pesquisadores	Ativo	Entradas	Saídas	Modelos	Métricas
(CAUX; BERNARDINI; VITERBO, 2020)	Bitcoin	Preço	Preço médio	LSTM, GRU	SMAPE
(FERDIANSYAH <i>et al.</i> , 2019)	Bitcoin	Preço	Preço	LSTM	RMSE
(SIAMI NAMINI; TAVAKOLI, 2019)	Ações	Preço	Preço	ARIMA, LSTM, BiLSTM	RMSE
(TRIPATHI; SHARMA, 2023)	Bitcoin	Preço ou indicadores	Preço	DANN, LSTM, BiLSTM, CNN-BiLSTM	RMSE, MAE, MAPE
Autor	Bitcoin	Preço, trocas e volume	Preço	ARIMA, LSTM, BiLSTM e GRU	MSE, MAPE, MASE, R^2

Figura: Estudos similares. Fonte: Próprio autor.

Fundamentação Teórica – Fundamentos conceituais

- A ideia de Ativos Digitais descentralizados baseados em criptografia, ou criptomoedas, foi marcada por inúmeras tentativas anteriores, mas só foi implementada como advento da *Blockchain* por (NAKAMOTO, 2008) (MOLLING *et al.*, 2020);
- O ARIMA (Autoregressive Integrated Moving Average) tem suas raízes na econometria e na estatística. Sua história remonta ao trabalho pioneiro de Box e Jenkins (1970);
- A teoria de Redes Neurais Artificiais teve início com os estudos de Rosenblatt (1957), evoluiu com Rumelhart, Hinton e Williams (1986). Atualmente, é associada ao aprendizado profundo proposto por Goodfellow, Bengio e Courville (2016).

Metodologia

Seção destinada a explicar como a pesquisa será realizada.

Metodologia – Classificação da pesquisa

- 1 Pode-se dizer, segundo a abordagem de Gerhardt e Silveira (2009), que a pesquisa adota uma abordagem quantitativa e experimental.
- 2 A natureza aplicada do estudo busca não apenas compreender as nuances de cada algoritmo, mas também oferecer insights para a seleção e implementação dos mais eficazes;
- 3 A metodologia descritiva permite uma análise detalhada dos resultados obtidos, destacando as diferenças significativas entre os modelos avaliados.

Metodologia – Solução proposta

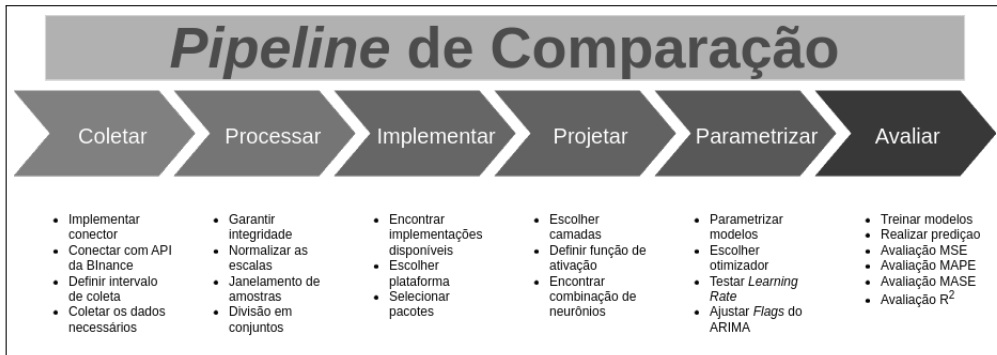


Figura: Fluxo de comparação. Fonte: Próprio autor.

Resultados

Resultados parciais encontrados no desenvolvimento da pesquisa.

Resultados

- 1 Ainda é inviável apresentar resultados, pois apesar da metodologia estar pronta, a pesquisa ainda não foi integralmente concluída;
- 2 Todos os dados foram coletados, sendo obtidas 35136 observações de preços;
- 3 As métricas de avaliação dos modelos foram definidas, sendo elas: *Mean Squared Error* (MSE), *Mean Absolute Scaled Error* (MASE), *Mean Absolute Percentage Error* (MAPE) e *R-squared* R^2 .

Conclusões

Conclusões e próximos passos.

Conclusões

- 1 A abordagem adotada para a implementação e avaliação dos algoritmos tem se mostrado adequada para os objetivos propostos;
- 2 A continuidade dos experimentos restantes são cruciais para validar os resultados e fornecer uma análise mais aprofundada.

Próximos passos

- Definir a arquitetura dos modelos a serem utilizados;
- Validar os parâmetros das redes e ARIMA;
- Implementar janelamento para a comparação.

Referências I

ARIYO, A. A.; ADEWUMI, A. O.; AYO, C. K. Stock Price Prediction Using the ARIMA Model. In: 2014 UKSim-AMSS 16th International Conference on Computer Modelling and Simulation. 2014. p. 106–112. DOI: 10.1109/UKSim.2014.67.

BACHELIER, L. Théorie de la Spéculation. **Annales Scientifiques de L'Ecole Normale Supérieure**, v. 17, p. 21–88, 1900.

BOX, G. E. P.; JENKINS, G. M. (M. **Time series analysis; forecasting and control**. Holden-Day, 1970.

FAMA, E. Random Walks in Stock Market Prices. **Financial Analysts Journal**, Routledge, v. 51, n. 1, p. 75–80, 1995.

FAMA, E. The Behavior of Stock-Market Prices. **The Journal of Business**, v. 38, p. 34, 1965.

Referências II

FERDIANSYAH, F. *et al.* A LSTM-Method for Bitcoin Price Prediction: A Case Study Yahoo Finance Stock Market. **2019 International Conference on Electrical Engineering and Computer Science (ICECOS)**, p. 206–210, 10/2019. DOI: 10.1109/ICECOS47637.2019.8984499.

GERHARDT, T.; SILVEIRA, D. **Métodos de pesquisa**. 1. ed.: UFRGS, 01/2009. p. 120. ISBN 9788538600718.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016.

MOLLING, G. *et al.* Cryptocurrency: A Mine of Controversies. **Journal of Information Systems and Technology Management**, v. 17, 12/2020. DOI: 10.4301/s1807-1775202017010.

Referências III

NAKAMOTO, S. **Bitcoin**: A Peer-to-Peer Electronic Cash System. 2008. Disponível em: <https://bitcoin.org/bitcoin.pdf>. Acesso em: 15/03/2024.

ROSENBLATT, F. **The perceptron, a perceiving and recognizing automaton**. Ithaca, New York, 1957.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986. Disponível em: <https://doi.org/10.1038/323533a0>.

SOUSA, A. *et al.* Cryptocurrency adoption: a systematic literature review and bibliometric analysis. **EuroMed Journal of Business**, v. 17, p. 374–390, 05/2022. DOI: 10.1108/EMJB-01-2022-0003.

Referências IV

ZHANG, J.; CAI, K.; WEN, J. A survey of deep learning applications in cryptocurrency. **iScience**, v. 27, n. 1, p. 108509, 2024. ISSN 2589-0042. DOI: <https://doi.org/10.1016/j.isci.2023.108509>.

Obrigado

Favor enviar as sugestões e os pedidos de correção para:
mickaelosvaldo1999@gmail.com
ciniro.nametala@ifmg.edu.br.

